

INTRODUÇÃO


Agentes de IA e o Model Context Protocol

Agentes de inteligência artificial deixaram de apenas gerar textos e passaram a interagir com arquivos, bancos de dados, APIs e outros sistemas. O Model Context Protocol (MCP) proposto pela Anthropic em 2024 padroniza essa integração ao permitir que servidores externos ofereçam ferramentas a aplicações de IA. Essa arquitetura amplia as capacidades dos agentes, mas também cria uma nova fronteira de segurança: uma ferramenta autorizada pode executar ações fora do próprio modelo e acessar recursos que exigem controle e supervisão.

JUSTIFICATIVA


- Mudanças perigosas após a aprovação: No ataque Rug Pull, uma ferramenta legítima é modificada após ser aprovada: nome, descrição e parâmetros podem permanecer iguais, enquanto o código passa a executar ações não autorizadas, mantendo a confiança da versão anterior (Bhatt et al., 2025).
- Risco real e difícil de identificar: Em 2025, o pacote postmark-mcp recebeu uma atualização maliciosa que passou a enviar cópias ocultas dos e-mails para um atacante (Postmark, 2025). Segundo Song et al. (2026), em estudo publicado pelo IEEE, pesquisadores revelaram a 20 participantes quais servidores eram maliciosos e pediram que identificassem como os ataques funcionavam. Mesmo assim, apenas 1 dos participantes identificou corretamente o ataque Rug Pull.
- Reconhecimento do risco e crescimento do ecossistema: Em 2026, a NSA (Agência de Segurança Nacional dos Estados Unidos) alertou que servidores MCP confiáveis podem ter capacidades ou acessos alterados sem nova aprovação, recomendando sua detecção e reavaliação. Segundo a Anthropic (2025), já existem milhares de servidores públicos, e Hasan et al. (2026), na ACM TOSEM, apontam que mecanismos tradicionais de segurança não cobrem todas as vulnerabilidades específicas do MCP.
- Da detecção à reavaliação: Hash identifica que uma ferramenta mudou, mas não se a alteração é perigosa. Inspirada na triagem de alertas com IA já utilizada na cibersegurança (Tariq et al., 2025), esta pesquisa compara hash, interface, código e análise combinada para distinguir alterações legítimas de maliciosas.

O que o MCP permite fazer?



Fonte: elaboração própria com ferramenta de IA, 2026.

Funcionamento do MCP



Fonte: elaborado pelos autores com base em Model Context Protocol (2026).

PROBLEMA

Quais estratégias de verificação conseguem identificar mudanças perigosas em ferramentas MCP previamente aprovadas, sem bloquear atualizações legítimas?

HIPÓTESE

Estratégias que analisam semanticamente as mudanças devem distinguir melhor alterações maliciosas de atualizações legítimas do que verificações puramente baseadas em alteração de arquivos, e a combinação de diferentes fontes de evidência pode reduzir os pontos cegos das análises isoladas, porém aumentando custo e tempo necessários.

OBJETIVO

Comparar estratégias para detectar mudanças maliciosas em ferramentas MCP após sua aprovação, avaliando capacidade de detecção, bloqueios incorretos, tempo e custo, e identificar quais evidências podem fundamentar mecanismos de reavaliação como o MCP Sentry.