


MCP SENTRY - DA PESQUISA À APLICAÇÃO

A pesquisa motivou uma aplicação prática: verificar se um servidor MCP local continua correspondente à versão aprovada antes de iniciá-lo. O MCP Sentry atua entre o cliente de IA e o servidor, comparando arquivos, configuração e metadados. Se houver mudança, mantém o servidor parado e oferece evidências para revisão. **A IA recomenda; o operador decide sobre a versão revisada.** A execução autorizada utiliza uma cópia verificada dos arquivos selecionados.



EVOLUÇÃO PROPOSTA - INTEGRAÇÃO NATIVA

O gateway é uma prova de conceito de um controle que poderia integrar o próprio cliente de IA: verificar mudanças antes de iniciar o servidor e reunir evidências, análise e decisão no mesmo fluxo de uso. A referência e a autorização devem permanecer protegidas contra alterações pelo agente.

- Hoje:** cliente de IA → gateway Sentry → servidor local
- Proposta:** cliente com controle integrado → servidor local
- Integração nativa:** proposta futura, ainda não implementada.

CONCLUSÕES

No núcleo N-INT, a combinação de interface e código bloqueou **84% das mudanças perigosas** e permitiu **88% das benignas**, entre as decisões válidas. Esses resultados pertencem aos cenários avaliados e não demonstram eficácia universal.

Além da bateria experimental, o trabalho produziu um gateway que coloca a verificação de mudanças no caminho de execução. Há registros técnicos de bloqueio antes do início em cenários controlados.

A validação completa da candidata atual em clientes reais permanece pendente. Como evolução, propõe-se integrar esse controle ao cliente de IA, preservando a decisão do operador.

REFERÊNCIAS

- ANTHROPIC. Introducing the Model Context Protocol. 2024. Disponível em: anthropic.com/news/model-context-protocol. Acesso em: 11 set. 2026.
- ANTHROPIC. Donating the Model Context Protocol and establishing the Agentic AI Foundation. 2025. Disponível em: anthropic.com/news/donating-the-model-context-protocol-and-establishing-of-the-agentic-ai-foundation. Acesso em: 11 set. 2026.
- BHATT, M.; NARAJALA, V. S.; HABLER, I. ETDI: Mitigating Tool Squatting and Rug Pull Attacks in Model Context Protocol (MCP) by using OAuth-Enhanced Tool Definitions and Policy-Based Access Control. arXiv:2506.01333, 2025. Disponível em: arxiv.org/abs/2506.01333. Acesso em: 12 set. 2026.
- HASAN, M. M. et al. Model Context Protocol (MCP) at First Glance: Studying the Security and Maintainability of MCP Servers. ACM Transactions on Software Engineering and Methodology, 2026. DOI: 10.1145/3814959. Disponível em: doi.org/10.1145/3814959. Acesso em: 12 set. 2026.
- HUANG, Y. et al. From Component Manipulation to System Compromise: Understanding and Detecting Malicious MCP Servers. arXiv:2604.01905, 2026. Disponível em: arxiv.org/abs/2604.01905. Acesso em: 13 set. 2026.
- MODEL CONTEXT PROTOCOL. Architecture. 2025. Disponível em: modelcontextprotocol.io/specification/2025-06-18/architecture. Acesso em: 13 set. 2026.
- NATIONAL SECURITY AGENCY. Model Context Protocol (MCP): Security Design Considerations for AI-Driven Automation. 2026. Disponível em: nsa.gov. Acesso em: 14 set. 2026.
- POSTMARK. Information Regarding Malicious “postmark-mcp” Package. 2025. Disponível em: postmarkapp.com/blog/information-regarding-malicious-postmark-mcp-package. Acesso em: 14 set. 2026.
- SONG, H. et al. Beyond the Protocol: Unveiling Attack Vectors in the Model Context Protocol (MCP) Ecosystem. IEEE Transactions on Software Engineering, v. 52, n. 8, p. 2410–2426, 2026. DOI: 10.1109/TSE.2026.3694876. Disponível em: doi.org/10.1109/TSE.2026.3694876. Acesso em: 15 set. 2026.
- TARIQ, S. et al. Alert Fatigue in Security Operations Centres: Research Challenges and Opportunities. ACM Computing Surveys, v. 57, n. 9, art. 224, p. 1–38, 2025. DOI: 10.1145/3723158. Disponível em: doi.org/10.1145/3723158. Acesso em: 15 set. 2026.
- WANG, Z. et al. MCPTox: A Benchmark for Tool Poisoning on Real-World MCP Servers. Proceedings of the AAAI Conference on Artificial Intelligence, v. 40, n. 42, p. 35811–35819, 2026. DOI: 10.1609/aaai.v40i42.40895. Disponível em: doi.org/10.1609/aaai.v40i42.40895. Acesso em: 16 set. 2026.
- YANG, Y.; WU, D.; CHEN, Y. MCPSecBench: A Systematic Security Benchmark and Playground for Testing Model Context Protocols. arXiv:2508.13220, 2025. Disponível em: arxiv.org/abs/2508.13220. Acesso em: 16 set. 2026.